Introducción a la Ciencia de Datos

Maestría en Probabilidad y Estadística

Dr. Marco Antonio Aquino López

Centro de Investigación en Matemáticas

Agosto–Diciembre 2026



Ciencia de Datos

- **Adquisición & Gestión**: fuentes, bases, APIs.
- **Preprocesamiento & EDA**: limpieza, codificación, escalamiento, visualización.
- **Modelado**: ML y modelos estadísticos.
- **Validación**: métricas, incertidumbre.
- **Comunicación**: reportes, dashboards, decisiones.

Idea clave

ML es el *mecanismo de predicción*
Modelos estadísticos es el proceso por el cual se hace inferencia sobre los parametros

Lo que ML *no* reemplaza

- **Diseño experimental**: sin buen diseño, hay sesgos irrecuperables.
- **Gestión de datos**: calidad, versionado, gobernanza.
- **Comunicación**: interpretabilidad, narrativa, ética.
- **Conocimiento de dominio**: define supuestos y utilidad de los modelos.

Resultados esperados

- **Predicción** y **explicación** con incertidumbre cuantificada.
- **Reproducibilidad**: trazabilidad de datos y código.
- **Impacto**: decisiones informadas en el dominio (salud, ambiente, finanzas, etc.).

Estadística, Computación y Matemáticas

- **Estadística**: inferencia, diseño, teoría de la decisión, modelos probabilísticos.
- **Computación**: algoritmos, estructuras de datos, bases, sistemas distribuidos.
- **Matemáticas**: optimización (convexa/no convexa), álgebra lineal, probabilidad, info. teórica.

Resumen

- La estadística/ML es el motor de *modelado* dentro del ciclo de Ciencia de Datos.
- Ciencia de Datos abarca desde *datos crudos* hasta *decisiones* con ética y reproducibilidad.

¿Que se considera ML?

- **Aprendizaje supervisado**: regresión, clasificación.
- **Aprendizaje no supervisado**: clustering, reducción de dimensión.
- **Aprendizaje por refuerzo**: políticas de decisión.

¿Qué es el Aprendizaje Supervisado?

- Se dispone de un conjunto de datos con pares (X_i, Y_i):

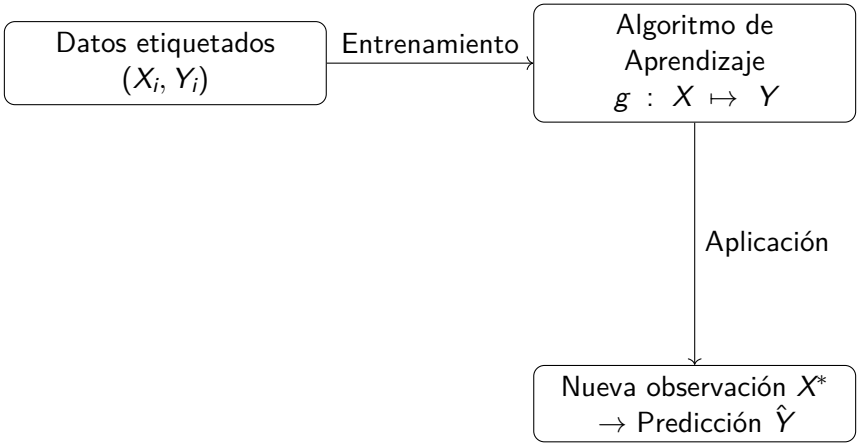
$$\{(X_1, Y_1), \ldots, (X_n, Y_n)\},$$

  donde X_i son las variables explicativas (predictores) y Y_i es la variable respuesta (etiqueta).
- Objetivo: aprender una función g tal que $g(X)$ prediga Y con el menor error posible.
- Dos tipos de problema:
  1. **Clasificación**: Y es categórica (p. ej., correo *spam*/*no spam*).
  2. **Regresión**: Y es continua (p. ej., precio de una casa).

Técnicas Estadísticas que conforman el Aprendizaje Supervisado

- **Clasificación óptima y regla de Bayes** *(clasificación)*.
- **Regresión lineal y logística** *(regresión / clasificación binaria)*.
- **Discriminantes lineales**: LDA, QDA, criterio de Fisher *(clasificación)*.
- **k-Vecinos más cercanos (k-NN)** *(clasificación y regresión)*.
- **Árboles de decisión y bosques aleatorios** *(clasificación y regresión)*.

Esquema del Aprendizaje Supervisado



¿Qué es la clasificación?

Preguntas naturales:

- ¿Qué son los objetos a clasificar?
- ¿Cómo definimos una **regla de clasificación**?
- ¿Cómo medir si la clasificación es buena o mala?
- ¿Cómo optimizar la regla?

Regla de clasificación

- Los datos son vectores $X \in \mathbb{R}^p$.
- Cada dato tiene una etiqueta $Y \in \{1, \ldots, K\}$.
- Una **regla de clasificación** es

$$g : \mathbb{R}^p \to \{1, \ldots, K\}, \quad x \mapsto g(x).$$

- Induce una partición:

$$\mathbb{R}^p = R_1 \cup \cdots \cup R_K, \quad R_k = \{x : g(x) = k\}.$$

Clasificación óptima

Cada sub-conjunto de datos $C_i = \{X_j : Y_j = i\}$ se llama *población i* o *cluster i*. Denotaremos $\{X \to R_i\}$ el evento que el punto X sea categorizado en R_i.

Suponemos que los datos de la población C_i tienen una cierta distribución subyacente de densidad f_i y que tiene una probabilidad de inclusión

$$\pi_i \;=\; P(X \to C_i).$$

Sea E el evento de hacer un error de clasificación. Entonces

$$\begin{aligned} P(E) &= \sum_{i=1}^{K} P\big(E \cap \{X \to C_i\}\big) = \sum_{i=1}^{K} P(X \to C_i)\, P\big(E \mid \{X \to C_i\}\big) \\ &= \sum_{i=1}^{K} \pi_i\, P\big(E \mid \{X \to C_i\}\big) = \sum_{i=1}^{K} \pi_i \Big(1 - P\big(X \in R_i \mid \{X \to C_i\}\big)\Big) \\ &= 1 - \sum_{i=1}^{K} \pi_i \int_{R_i} f_i(x)\, dx. \end{aligned}$$

Clasificación óptima

Definimos, para cada i,

$$q_i(x) \;=\; P\big(X \to C_i \mid X = x\big).$$

Por la regla de Bayes,

$$q_i(x) = \frac{\pi_i \, P(X = x \mid X \to C_i)}{P(X = x)} = \frac{\pi_i f_i(x)}{\sum_{j=1}^{K} \pi_j f_j(x)}.$$

Además, $P(X = x) = \sum_{j=1}^{K} \pi_j f_j(x)$, de tal manera que

$$P(\mathrm{NoErr}(g)) = \sum_{i=1}^{K} \int_{R_i} q_i(x) \, P(X = x) \, dx = \int_{\mathbb{R}^p} P(X = x) \left(\sum_{i=1}^{K} \mathbf{1}_{\{x \in R_i\}} \, q_i(x) \right) dx.$$

Clasificación óptima

Vimos que la probabilidad de no hacer errores en una regla de clasificación g está dada por

$$P(\text{NoErr}(g)) \;=\; \int P(X = x)\, h_g(x)\, dx, \qquad h_g(x) \;=\; \sum_{i=1}^{K} \mathbf{1}_{\{x \in R_i\}}\, q_i(x).$$

Consideramos la regla g^* dada por las regiones

$$R_i^* \;=\; \left\{x \in \mathbb{R}^p : \forall j,\; q_i(x) \geq q_j(x)\right\}.$$

Sea g cualquier otra regla. Para un x dado, existe j tal que $x \in R_j$ y m tal que $x \in R_m^*$. Por definición de g^*,

$$q_m(x) \;\geq\; q_j(x) \;\Rightarrow\; h_g(x) \;=\; \sum_{i=1}^{K} \mathbf{1}_{\{x \in R_i\}}\, q_i(x) \;=\; q_j(x) \;\leq\; q_m(x) = \sum_{i=1}^{K} \mathbf{1}_{\{x \in R_i^*\}}\, q_i(x) \;=\; h_{g^*}(x).$$

Clasificación óptima

Entonces,

$$P(\mathrm{NoErr}(g)) \;=\; \int P(X=x)\, h_g(x)\, dx \;\leq\; \int P(X=x)\, h_{g^*}(x)\, dx \;=\; P(\mathrm{NoErr}(g^*)).$$

La regla g^* es óptima para el criterio "probabilidad de errores".

Cálculo de R_i^*: encontrar R_i^* equivale a comparar los valores $\pi_1 f_1(x), \ldots, \pi_K f_K(x)$. Si conocemos $\{\pi_i, f_i\}$, el algoritmo es:

1. **Input:** x
2. Calcular $\pi_1 f_1(x), \ldots, \pi_K f_K(x)$
3. Calcular $k = \arg\max_i \pi_i f_i(x)$
4. $k \to Y$
5. **Output:** Y

Clasificación óptima de poblaciones normales

Si tenemos K poblaciones *normales* de proporciones π_i **iguales**,

$$f_i(x) = \frac{1}{(2\pi)^{p/2}\,|\Sigma_i|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu_i)^\top \Sigma_i^{-1}(x-\mu_i) \right).$$

Las **fronteras** de las regiones R_i^* son de la forma $f_i(x) = f_j(x)$ sujeto a $\forall k \neq i, j,\ f_k(x) \leq f_i(x)$.

Error de Bayes

En general, una regla óptima g^* satisface

$$g^* \;=\; \arg \min_{g:\, \mathbb{R}^p \to \{1,\ldots,K\}} P\big(g(X) \neq Y\big).$$

La cantidad $L(g) = P\big(g(X) \neq Y\big)$ es la misma utilizada antes. El número real $L(g^*)$ se llama **error de Bayes**.

El error de Bayes es una *noción teórica* y no se puede calcular en la práctica salvo en casos particulares:

La distribución de (X, Y) es generalmente desconocida.

Un clasificador real se construye con datos $(X_1, Y_1), \ldots, (X_n, Y_n)$. Denotamos g_n a dicho clasificador; su error teórico es $L(g_n)$ y su error *estimado* es

$$L_n(g_n) \;=\; P\big(g(X) \neq Y \,|\, \text{“datos”}\big).$$

Riesgo condicional y regla de decisión

Contexto de dos clases $Y \in \{0, 1\}$. Denotamos

$$\eta(x) \;=\; P(Y = 1 \mid X = x).$$

En este contexto, el riesgo esperado es

$$L(g) = \Pr\big(g(X) \neq Y\big).$$

Podemos descomponerlo como

$$L(g) = \mathbb{E}\big[\, \Pr(g(X) \neq Y \mid X)\,\big].$$

Riesgo condicional y regla de decisión

Contexto de dos clases $Y \in \{0, 1\}$. Denotamos

$$\eta(x) \;=\; P(Y = 1 \mid X = x).$$

En este contexto, el riesgo esperado es

$$L(g) = \Pr\big(g(X) \neq Y\big).$$

Podemos descomponerlo como

$$L(g) = \mathbb{E}\big[\, \Pr(g(X) \neq Y \mid X)\,\big].$$

Riesgo condicional: dado $X = x$:

$$\Pr(\text{error} \mid X = x, g(x) = 1) = \Pr(Y = 0 \mid X = x) = 1 - \eta(x),$$
$$\Pr(\text{error} \mid X = x, g(x) = 0) = \Pr(Y = 1 \mid X = x) = \eta(x).$$

Riesgo condicional y regla de decisión

Contexto de dos clases $Y \in \{0, 1\}$. Denotamos

$$\eta(x) \;=\; P(Y = 1 \mid X = x).$$

En este contexto, el riesgo esperado es

$$L(g) = \Pr\big(g(X) \neq Y\big).$$

Podemos descomponerlo como

$$L(g) = \mathbb{E}\big[\, \Pr(g(X) \neq Y \mid X)\,\big].$$

Riesgo condicional: dado $X = x$:

$$\Pr(\text{error} \mid X = x, g(x) = 1) = \Pr(Y = 0 \mid X = x) = 1 - \eta(x),$$

$$\Pr(\text{error} \mid X = x, g(x) = 0) = \Pr(Y = 1 \mid X = x) = \eta(x).$$

La **regla de Bayes** consiste en elegir, para cada x, la clase que minimiza la probabilidad de error condicional:

$$g^*(x) = \arg \min_{y \in \{0,1\}} \Pr(\text{error} \mid X = x, g(x) = y).$$

De Bayes $\rightarrow$ Naive Bayes

El clasificador óptimo es

$$g^*(x) = \arg\max_k \ \pi_k \, f_k(x), \qquad x = (x_1, \ldots, x_p).$$

Por la *chain rule*:

$$\begin{aligned} f_k(x) = P(X_1 = x_1 \mid Y = k)\, P(X_2 = x_2 \mid X_1 = x_1, Y = k) \cdots \\ \times P(X_p = x_p \mid X_1 = x_1, \ldots, X_{p-1} = x_{p-1}, Y = k). \end{aligned}$$

De Bayes $\rightarrow$ Naive Bayes

El clasificador óptimo es

$$g^*(x) = \arg\max_k \ \pi_k \, f_k(x), \qquad x = (x_1, \ldots, x_p).$$

Por la *chain rule*:

$$f_k(x) = P(X_1 = x_1 \mid Y = k)\, P(X_2 = x_2 \mid X_1 = x_1, Y = k) \cdots \\ \times P(X_p = x_p \mid X_1 = x_1, \ldots, X_{p-1} = x_{p-1}, Y = k).$$

Supuesto Naive (independencia condicional):

$$X_1, \ldots, X_p \ \perp\!\!\!\perp \ \text{dado } Y = k \quad \Longrightarrow \quad f_k(x) = \prod_{j=1}^{p} f_{k,j}(x_j).$$

De Bayes $\rightarrow$ Naive Bayes

El clasificador óptimo es

$$g^*(x) = \arg\max_k \ \pi_k \, f_k(x), \qquad x = (x_1, \ldots, x_p).$$

Por la *chain rule*:

$$f_k(x) = P(X_1 = x_1 \mid Y = k)\, P(X_2 = x_2 \mid X_1 = x_1, Y = k) \cdots \\ \times P(X_p = x_p \mid X_1 = x_1, \ldots, X_{p-1} = x_{p-1}, Y = k).$$

Supuesto Naive (independencia condicional):

$$X_1, \ldots, X_p \ \perp\!\!\!\perp \ \text{dado } Y = k \quad \Longrightarrow \quad f_k(x) = \prod_{j=1}^{p} f_{k,j}(x_j).$$

Regla de decisión (en log para evitar underflow):

$$\boxed{g_{\text{NB}}(x) = \arg\max_k \left[\log \pi_k + \sum_{j=1}^{p} \log f_{k,j}(x_j) \right]}$$

Estimación de $f_{k,j}$: variables **continuas**

Gaussian Naive Bayes (una normal por atributo y clase):

$$x_j \mid Y = k \sim \mathcal{N}(\mu_{kj}, \sigma^2_{kj}), \qquad f_{k,j}(x_j) = \frac{1}{\sqrt{2\pi\sigma^2_{kj}}} \exp\left(-\frac{(x_j - \mu_{kj})^2}{2\sigma^2_{kj}}\right).$$

Estimadores MLE con los datos de la clase k:

$$\widehat{\mu}_{kj} = \frac{1}{n_k} \sum_{i:y_i=k} x_{ij}, \qquad \widehat{\sigma}^2_{kj} = \frac{1}{n_k} \sum_{i:y_i=k} (x_{ij} - \widehat{\mu}_{kj})^2.$$

Implementación práctica

Entrenamiento

1. Estimar $\widehat{\pi}_k$ para cada clase k.
2. Para cada atributo j y clase k: estimar $f_{k,j}$ (Bernoulli/Multinomial/Gaussian).

Predicción para un x nuevo

$$\text{score}_k(x) = \log \widehat{\pi}_k + \sum_{j=1}^{p} \log \widehat{f}_{k,j}(x_j), \quad \widehat{y} = \arg\max_k \text{score}_k(x).$$

Detalles numéricos & prácticos

- Trabajar en log para evitar underflow.
- Suavizado de Laplace ($\alpha > 0$) evita probabilidades nulas.

Ventajas y límites (cuándo usarlo)

Ventajas

- Muy rápido y simple; escala bien a alta dimensión y datos dispersos.
- Mezcla natural de variables discretas y continuas.
- Sorprendentemente competitivo como línea base (texto, filtrado de spam, etc.).

Limitaciones

- El supuesto de independencia condicional puede ser falso (atributos correlacionados).
- Puede estar mal calibrado en probabilidades; considerar *calibration* posterior.
- Decisiones sesgadas si hay desbalance severo sin ajustar π_k o umbrales.

Cuándo funciona bien

- Como base rápida para comparar con modelos más complejos.

Caso Gaussiano: Discriminante Lineal

- Supongamos: $X|Y = k \sim N_p(\mu_k, \Sigma)$, con $k = 1, 2$.
- La densidad conjunta es $f_k(x) = (2\pi)^{-p/2}|\Sigma|^{-1/2}\exp\{-\frac{1}{2}(x-\mu_k)^\top\Sigma^{-1}(x-\mu_k)\}$.
- La regla de Bayes compara $\pi_2 f_2(x)$ y $\pi_1 f_1(x)$.

Caso Gaussiano: Discriminante Lineal

- Supongamos: $X|Y = k \sim N_p(\mu_k, \Sigma)$, con $k = 1, 2$.
- La densidad conjunta es $f_k(x) = (2\pi)^{-p/2}|\Sigma|^{-1/2}\exp\{-\frac{1}{2}(x-\mu_k)^\top\Sigma^{-1}(x-\mu_k)\}$.
- La regla de Bayes compara $\pi_2 f_2(x)$ y $\pi_1 f_1(x)$.

Regla de Decisión

Asignar x a la clase 2 si

$$(\mu_2 - \mu_1)^\top\Sigma^{-1}x > \log\frac{\pi_1}{\pi_2} + \frac{1}{2}(\mu_2 + \mu_1)^\top\Sigma^{-1}(\mu_2 - \mu_1).$$

Regla de Decisión para Dos Poblaciones Normales (LDA)

Sea $X|Y = k \sim N_p(\mu_k, \Sigma)$ con Σ común y prior π_k. Asignar x a la clase 2 si:

$$\pi_2 f_2(x) > \pi_1 f_1(x)$$

es decir

$$\frac{\pi_2}{(2\pi)^{p/2}|\Sigma|^{1/2}} e^{-\frac{1}{2}(x-\mu_2)^T\Sigma^{-1}(x-\mu_2)} > \frac{\pi_1}{(2\pi)^{p/2}|\Sigma|^{1/2}} e^{-\frac{1}{2}(x-\mu_1)^T\Sigma^{-1}(x-\mu_1)}$$

Regla de Decisión para Dos Poblaciones Normales (LDA)

Sea $X|Y = k \sim N_p(\mu_k, \Sigma)$ con Σ común y prior π_k. Asignar x a la clase 2 si:

$$\pi_2 f_2(x) > \pi_1 f_1(x)$$

es decir

$$\frac{\pi_2}{(2\pi)^{p/2}|\Sigma|^{1/2}} e^{-\frac{1}{2}(x-\mu_2)^T\Sigma^{-1}(x-\mu_2)} > \frac{\pi_1}{(2\pi)^{p/2}|\Sigma|^{1/2}} e^{-\frac{1}{2}(x-\mu_1)^T\Sigma^{-1}(x-\mu_1)}$$

Tomando logaritmos y desarrollando términos cuadráticos:

$$-\frac{1}{2}(x-\mu_2)^T\Sigma^{-1}(x-\mu_2) > \log\frac{\pi_1}{\pi_2} - \frac{1}{2}(x-\mu_1)^T\Sigma^{-1}(x-\mu_1)$$

Regla de Decisión para Dos Poblaciones Normales (LDA)

Sea $X|Y=k \sim N_p(\mu_k, \Sigma)$ con Σ común y prior π_k. Asignar x a la clase 2 si:

$$\pi_2 f_2(x) > \pi_1 f_1(x)$$

es decir

$$\frac{\pi_2}{(2\pi)^{p/2}|\Sigma|^{1/2}} e^{-\frac{1}{2}(x-\mu_2)^T\Sigma^{-1}(x-\mu_2)} > \frac{\pi_1}{(2\pi)^{p/2}|\Sigma|^{1/2}} e^{-\frac{1}{2}(x-\mu_1)^T\Sigma^{-1}(x-\mu_1)}$$

Tomando logaritmos y desarrollando términos cuadráticos:

$$-\frac{1}{2}(x-\mu_2)^T\Sigma^{-1}(x-\mu_2) > \log\frac{\pi_1}{\pi_2} - \frac{1}{2}(x-\mu_1)^T\Sigma^{-1}(x-\mu_1)$$

Simplificando:

$$(\mu_2-\mu_1)^T\Sigma^{-1}x > \log\frac{\pi_1}{\pi_2} + \frac{1}{2}\left(\mu_2^T\Sigma^{-1}\mu_2 - \mu_1^T\Sigma^{-1}\mu_1\right)$$

Regla de Decisión para Dos Poblaciones Normales (LDA)

Sea $X|Y=k \sim N_p(\mu_k, \Sigma)$ con Σ común y prior π_k. Asignar x a la clase 2 si:

$$\pi_2 f_2(x) > \pi_1 f_1(x)$$

es decir

$$\frac{\pi_2}{(2\pi)^{p/2}|\Sigma|^{1/2}} e^{-\frac{1}{2}(x-\mu_2)^T\Sigma^{-1}(x-\mu_2)} > \frac{\pi_1}{(2\pi)^{p/2}|\Sigma|^{1/2}} e^{-\frac{1}{2}(x-\mu_1)^T\Sigma^{-1}(x-\mu_1)}$$

Tomando logaritmos y desarrollando términos cuadráticos:

$$-\frac{1}{2}(x-\mu_2)^T\Sigma^{-1}(x-\mu_2) > \log\frac{\pi_1}{\pi_2} - \frac{1}{2}(x-\mu_1)^T\Sigma^{-1}(x-\mu_1)$$

Simplificando:

$$(\mu_2-\mu_1)^T\Sigma^{-1}x > \log\frac{\pi_1}{\pi_2} + \frac{1}{2}\left(\mu_2^T\Sigma^{-1}\mu_2 - \mu_1^T\Sigma^{-1}\mu_1\right)$$

Finalmente, se obtiene una regla lineal:

$$w^T x > w_0, \qquad w = \Sigma^{-1}(\mu_2-\mu_1), \quad w_0 = \log\frac{\pi_1}{\pi_2} + \frac{1}{2}\left(\mu_2^T\Sigma^{-1}\mu_2 - \mu_1^T\Sigma^{-1}\mu_1\right)$$

Caso Gaussiano: Discriminante Lineal

Regla de Decisión

Asignar x a la clase 2 si

$$(\mu_2 - \mu_1)^\top \Sigma^{-1} x > \log \frac{\pi_1}{\pi_2} + \frac{1}{2}(\mu_2 + \mu_1)^\top \Sigma^{-1}(\mu_2 - \mu_1).$$

- Definimos:

$$w = \Sigma^{-1}(\mu_2 - \mu_1), \qquad w_0 = \log \frac{\pi_1}{\pi_2} + \frac{1}{2}(\mu_2 + \mu_1)^\top \Sigma^{-1}(\mu_2 - \mu_1)$$

- Clasificador:

$$g(x) = \begin{cases} 2, & w^\top x > w_0 \\ 1, & w^\top x \leq w_0. \end{cases}$$

- La frontera de decisión es un **hiperplano**: $\{x : w^\top x = w_0\}$.

Interpretación Geométrica

- Los datos se proyectan sobre la dirección w.
- La clasificación depende de si x cae a la izquierda o derecha de la frontera.

Motivación del Criterio de Fisher

- Consideremos dos poblaciones con medias $\hat{m}_0, \hat{m}_1$ y matrices de covarianza S_0, S_1.
- Queremos proyectar los datos $X \in \mathbb{R}^p$ sobre una dirección a y luego clasificar en 1D.
- Idea: elegir a de manera que las proyecciones $z_i = a^T X_i$ estén lo más separadas posible entre clases.

Definición Formal del Criterio de Fisher

Criterio

$$J(a) = \frac{\left(a^T(\hat{m}_1 - \hat{m}_0)\right)^2}{a^T S_w a} \qquad \text{donde } S_w = S_0 + S_1 \text{ es la matriz de dispersión intra-clase}$$

- El numerador representa la **separación entre clases** en la dirección a.
- El denominador representa la **variabilidad dentro de las clases** en la dirección a.
- Queremos maximizar $J(a)$ para encontrar la dirección de proyección óptima.

Construcción de $J(a)$: de datos p-dimensionales a 1D

Paso 1. Proyección y medias proyectadas. Dado $a \in \mathbb{R}^p$, definimos $z = a^\top x$. Las medias de clase proyectadas son $\bar{z}_k = a^\top \hat{m}_k \, (k = 0, 1)$ y la media global $\bar{z} = a^\top \hat{m}$.

Paso 2. Dispersión entre clases en 1D. La separación de medias proyectadas es $\left(\bar{z}_1 - \bar{z}_0\right)^2 = \left(a^\top (\hat{m}_1 - \hat{m}_0)\right)^2$.

Paso 3. Dispersión intra-clase en 1D. La varianza total dentro de clases tras proyectar es

$$s_w^2(a) \;=\; \sum_{k \in \{0,1\}} \sum_{i \in C_k} \left(a^\top x_i - a^\top \hat{m}_k\right)^2 \;=\; a^\top \Big(\underbrace{\sum_k \sum_{i \in C_k} (x_i - \hat{m}_k)(x_i - \hat{m}_k)^\top}_{S_w} \Big) a \;=\; a^\top S_w a.$$

Paso 4. Criterio adimensional (cociente de Rayleigh) agregué una diapositiva de biblio. Para comparar "separación/variabilidad" en la misma escala:

$$J(a) = \frac{\left(a^\top(\hat{m}_1 - \hat{m}_0)\right)^2}{a^\top S_w a}.$$

Observaciones.

- $J(a)$ es invariante a re-escalamientos de a (si $a \leftarrow c\,a$, numerador y denominador se multiplican por c^2).
- Maximizar $J(a) \iff$ resolver $\max (a^\top \Delta m)^2$ s.a. $a^\top S_w a = 1$ con $\Delta m = \hat{m}_1 - \hat{m}_0$.

Optimización de $J(a)$

- Como $J(a)$ es invariante a la escala de a, podemos imponer la restricción $a^T S_w a = 1$.
- Entonces el problema es:

$$\max_a \quad (a^T(\hat{m}_1 - \hat{m}_0))^2 \quad \text{sujeto a } a^T S_w a = 1$$

- Resolviendo con multiplicadores de Lagrange, la condición de primer orden es:

$$S_w a = \lambda(\hat{m}_1 - \hat{m}_0)$$

- Solución:

$$a^* = S_w^{-1}(\hat{m}_1 - \hat{m}_0)$$

Interpretación de a^*

- a^* es la dirección que maximiza la razón "varianza entre clases / varianza dentro de clases".
- En el espacio proyectado $z = {a^*}^T x$ obtenemos una variable 1D con máxima separabilidad.
- Luego podemos usar un umbral z_0 (por ejemplo, el punto medio entre medias proyectadas) para clasificar.

Discriminante Cuadrático (QDA)

- Si $X|Y = k \sim N_p(\mu_k, \Sigma_k)$ con matrices de covarianza **diferentes**, la regla de Bayes se vuelve cuadrática.
- La función discriminante para la clase k es:

$$\delta_k(x) = -\frac{1}{2}\log|\Sigma_k| - \frac{1}{2}(x-\mu_k)^\top \Sigma_k^{-1}(x-\mu_k) + \log \pi_k$$

- Clasificamos x en la clase con mayor $\delta_k(x)$.

Discriminante Cuadrático (QDA) - Detalles Formales

Supongamos $X|Y=k \sim N_p(\mu_k, \Sigma_k)$ con matrices de covarianza **distintas**. La densidad de clase k es:

$$f_k(x) = \frac{1}{(2\pi)^{p/2}|\Sigma_k|^{1/2}} \exp\Big[-\tfrac{1}{2}(x-\mu_k)^T\Sigma_k^{-1}(x-\mu_k)\Big]$$

La regla de Bayes asigna x a la clase k que maximiza $\pi_k f_k(x)$. Tomando logaritmos:

$$\log \pi_k - \frac{1}{2}\log|\Sigma_k| - \frac{1}{2}(x-\mu_k)^T\Sigma_k^{-1}(x-\mu_k)$$

Definimos la función discriminante cuadrática:

$$\delta_k(x) = -\frac{1}{2}\log|\Sigma_k| - \frac{1}{2}(x-\mu_k)^T\Sigma_k^{-1}(x-\mu_k) + \log \pi_k$$

- La frontera de decisión $\delta_1(x) = \delta_2(x)$ es una **cuádrica** en x (elipsoide, parábola, hipérbola según el caso).
- Si $\Sigma_1 = \Sigma_2$, se recupera el discriminante lineal de LDA.

Bibliografía

- Hastie, T., Tibshirani, R., Friedman, J. (2009). *The Elements of Statistical Learning*. Springer, 2nd Ed.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Murphy, K. P. (2012). *Machine Learning: A Probabilistic Perspective*. MIT Press.
- Friedman, J. (1989). Regularized Discriminant Analysis. *Journal of the American Statistical Association*, 84(405), 165–175.
- Rao, C. R. (1973). *Linear Statistical Inference and Its Applications*. Wiley.
- Venables, W. N., Ripley, B. D. (2002). *Modern Applied Statistics with S*. Springer.