Tarea: datos, outliers, estimación de densidades y clasificación óptima

Curso de Ciencia de Datos

Indicaciones. Esta tarea busca practicar los conceptos vistos hasta ahora en el curso. En cada ejercicio se debe mostrar el razonamiento. Una respuesta numérica o un programa sin explicación no es suficiente.

Para la parte de programación se pueden utilizar herramientas básicas para generar números aleatorios, hacer operaciones matemáticas y producir gráficas. No se pueden utilizar funciones que construyan directamente histogramas o estimadores de densidad kernel, por ejemplo `hist`, `histogram`, `gaussian_kde`, `KernelDensity` o equivalentes.

1. Clasificador óptimo para dos poblaciones normales

Suponga que una observación X puede provenir de una de dos poblaciones,

$$X \mid C_1 \sim \mathcal{N}(\mu_1, \sigma_1^2), \qquad X \mid C_2 \sim \mathcal{N}(\mu_2, \sigma_2^2),$$

con

$$P(C_1) = \pi_1, \qquad P(C_2) = \pi_2, \qquad \pi_1 + \pi_2 = 1.$$

a) Utilizando el teorema de Bayes, escriba

$$P(C_1 \mid X = x) \qquad \text{y} \qquad P(C_2 \mid X = x).$$

b) Partiendo únicamente de la regla

asignar x a la clase con mayor probabilidad posterior,

demuestre que el clasificador puede escribirse como una comparación entre

$$\pi_1 f_1(x) \qquad \text{y} \qquad \pi_2 f_2(x).$$

c) Sustituya las densidades normales y obtenga explícitamente la regla de clasificación.

d) Suponga ahora que

$$\sigma_1^2 = \sigma_2^2 = \sigma^2.$$

Demuestre que la frontera de clasificación es un punto x^*. Obtenga x^* en función de

$$\mu_1, \mu_2, \sigma^2, \pi_1, \pi_2.$$

e) ¿Qué cambia cuando $\sigma_1^2 \neq \sigma_2^2$? No es suficiente responder que la expresión es cuadrática: explique qué consecuencia puede tener esto sobre las regiones asignadas a cada clase.

2. Clasificador óptimo para dos distribuciones Gamma

Ahora suponga que $X > 0$ y

$$X \mid C_1 \sim \text{Gamma}(\alpha_1, \beta_1), \qquad X \mid C_2 \sim \text{Gamma}(\alpha_2, \beta_2),$$

donde se utilizará la parametrización *shape-rate*

$$f(x \mid \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \qquad x > 0.$$

a) Derive nuevamente el clasificador óptimo utilizando

$$P(C_j \mid x) \propto \pi_j f_j(x).$$

b) Tome logaritmos y demuestre que la decisión entre las dos clases puede escribirse en términos de una expresión de la forma

$$A + B \log x + Cx.$$

Identifique A, B y C.

c) Considere ahora

$$C_1 : \text{Gamma}(3, 1), \qquad C_2 : \text{Gamma}(3, 0.5),$$

con

$$\pi_1 = \pi_2 = 0.5.$$

Obtenga la frontera x^* del clasificador.

d) Dibuje aproximadamente las dos densidades y marque x^*. Utilice el dibujo para explicar por qué la regla obtenida tiene sentido.

e) Compare este resultado con el caso normal de la pregunta anterior. ¿Qué parte del procedimiento cambió y qué parte permaneció exactamente igual?

3. ¿Cuál observación es un outlier?

Cinco mediciones de radiocarbono obtenidas de muestras que, de acuerdo con el contexto arqueológico, deberían corresponder aproximadamente al mismo evento son:

i	Edad de radiocarbono (años BP)
1	4215
2	4241
3	4198
4	4690
5	4227

Suponga inicialmente que no tiene ninguna información adicional.

a) Mirando únicamente los datos, ¿cuál o cuáles observaciones consideraría sospechosas? Explique por qué. **No elimine ninguna observación.**

b) Se desea responder una pregunta distinta:

$$P(\text{observación } i \text{ es outlier} \mid \mathbf{x}).$$

Explique por qué los cinco números anteriores no son suficientes para calcular esta probabilidad. ¿Qué cantidades o supuestos adicionales necesita?

c) Proponga un modelo probabilístico para resolver el problema. Introduzca una variable

$$z_i = \begin{cases} 0, & \text{si } x_i \text{ pertenece al proceso esperado,} \\ 1, & \text{si } x_i \text{ es un outlier.} \end{cases}$$

Utilice, por ejemplo,

$$P(z_i = 1) = \pi,$$

una distribución Normal para las observaciones regulares y una distribución Uniforme sobre un intervalo amplio para los outliers. Escriba completamente su modelo.

d) Condicionando por ahora en valores conocidos de μ, σ, π, a, b, derive

$$P(z_i = 1 \mid x_i).$$

La respuesta debe obtenerse usando Bayes, no darse directamente.

e) Elija valores razonables para μ, σ, π, a, b, indicando claramente cómo los eligió. Calcule entonces

$$P(z_i = 1 \mid x_i)$$

para las cinco observaciones. ¿La observación que parecía sospechosa en el inciso (a) tiene necesariamente probabilidad posterior cercana a uno de ser un outlier? Explique.

4. Construcción de un histograma desde su definición

Genere muestras

$$X_1, \ldots, X_n \sim \mathcal{N}(0, 1)$$

para

$$n = 50, \qquad 500, \qquad 5000.$$

Puede utilizar una función para generar los números aleatorios, pero el histograma debe construirse directamente.

a) Defina una partición

$$b_0 < b_1 < \cdots < b_m$$

de un intervalo que contenga los datos. Para cada intervalo

$$B_j = [b_j, b_{j+1}),$$

calcule mediante su propio código

$$N_j = \sum_{i=1}^{n} I(X_i \in B_j).$$

No puede utilizar una función que cuente automáticamente las observaciones por intervalos.

b) A partir de N_j, construya un estimador de densidad

$$\widehat{f}(x) = \frac{N_j}{nh}, \qquad x \in B_j,$$

donde

$$h = b_{j+1} - b_j.$$

Compruebe numéricamente que el área total del histograma es aproximadamente uno.

c) Grafique sobre la misma figura la densidad real

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}.$$

Compare los resultados para $n = 50, 500, 5000$.

d) Mantenga ahora $n = 5000$ fijo y pruebe al menos tres valores diferentes de h. Explique qué ocurre cuando h es demasiado grande y cuando h es demasiado pequeño.

5. Kernel de densidad y convergencia

Utilice nuevamente muestras de

$$X_i \sim \mathcal{N}(0, 1).$$

Construya desde su definición el estimador kernel

$$\widehat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - X_i}{h}\right),$$

usando el kernel Gaussiano

$$K(u) = \frac{1}{\sqrt{2\pi}} e^{-u^2/2}.$$

No puede utilizar una función que calcule KDE directamente.

a) Escriba una función que reciba

$$x, \quad X_1, \ldots, X_n, \quad h$$

y devuelva $\widehat{f}_h(x)$ utilizando directamente la expresión anterior.

b) Calcule $\widehat{f}_h(x)$ sobre una malla de valores entre -4 y 4, y grafique simultáneamente

$$\widehat{f}_h(x) \qquad \text{y} \qquad f(x).$$

c) Repita el experimento con

$$n = 50, \quad 500, \quad 5000, \quad 50000$$

y una secuencia de valores h_n que disminuya cuando n aumenta. Debe cumplirse

$$h_n \to 0 \qquad \text{y} \qquad nh_n \to \infty.$$

Explique con sus propias palabras por qué necesitamos ambas condiciones.

d) Para medir la diferencia con la distribución real, utilice una malla

$$x_1, \ldots, x_M$$

y calcule

$$E_n = \frac{1}{M} \sum_{j=1}^{M} \left[\widehat{f}_{h_n}(x_j) - f(x_j) \right]^2 .$$

Haga una tabla con n, h_n y E_n. Muestre empíricamente qué ocurre con E_n al aumentar n.

e) Finalmente, explique la conexión entre su experimento y el resultado teórico

$$\widehat{f}_{h_n}(x) \longrightarrow f(x)$$

cuando

$$n \to \infty, \qquad h_n \to 0, \qquad n h_n \to \infty.$$

No se pide una demostración formal completa. Explique el papel de $h_n \to 0$ y de $n h_n \to \infty$ en términos de **sesgo** y **variabilidad**.