Centro de Investigación en Matemáticas
Maestría en Probabilidad y Estadística

Comparación y validación de clasificadores

Introducción a la Ciencia de Datos

Dr. Marco Antonio Aquino López

Entrega: reporte en PDF y código en Python

Problema y datos

Se desea explorar si es posible distinguir entre personas con y sin cálculos biliares a partir de variables demográficas, de composición corporal y de laboratorio. Tu trabajo consiste en comparar clasificadores y emitir una recomendación sustentada en evidencia sobre su desempeño en observaciones nuevas.

Trabajarás con los datos asociados al siguiente artículo:

> Esen, ., et al. (2024). *Early prediction of gallstone disease with a machine learning-based method from bioimpedance and laboratory data. Medicine*, **103**(8), e37258.
> Artículo de acceso abierto DOI: 10.1097/MD.0000000000037258.

Los datos están disponibles en UCI: Gallstone, con licencia CC BY 4.0, y fueron depositados en 2025. El archivo descargable contiene **319 observaciones y 38 variables predictoras**, además de la respuesta `Gallstone Status`. Su codificación original es **0 = presencia de cálculos; 1 = ausencia**. Define explícitamente qué considerarás la clase positiva al calcular las métricas.

Lee las partes del artículo necesarias para comprender el problema, la procedencia de los datos y el significado de las variables. La actividad no exige reproducir todos los experimentos del artículo ni alcanzar sus resultados.

Trabajo a realizar

1. **Comprende y prepara los datos.** Describe brevemente la muestra, las clases y las decisiones de preparación que consideres necesarias. Justifica cómo tratarás los distintos tipos de variables y sus escalas. Identifica limitaciones relevantes para interpretar los resultados.

2. **Compara los clasificadores vistos en clase:** Naive Bayes gaussiano, LDA, QDA y k-vecinos más cercanos. Explica brevemente los supuestos o características que podrían favorecer o perjudicar a cada uno en este problema. En k-NN explora unos pocos valores de k; las demás decisiones de configuración quedan a tu criterio. Si aparece inestabilidad numérica, documenta cómo la identificaste y resolviste. Puedes usar las implementaciones de las bibliotecas de Python.

3. **Diseña una evaluación justa.** Elige y justifica una técnica de validación de las estudiadas en clase: *hold-out*, validación cruzada y sus variantes, o *bootstrap*. Emplea las mismas particiones o remuestreos para comparar los métodos. Toda transformación que aprenda de los datos debe ajustarse únicamente con el conjunto de entrenamiento correspondiente. Si eliges parámetros o variables a partir de los resultados, distingue esa selección de la evaluación final del desempeño.

4. **Estima e interpreta los errores.** Para cada clasificador, presenta el **error aparente** y el **error estimado mediante tu estrategia de validación**, entendiendo por error la proporción de observaciones mal clasificadas. Incluye una matriz de confusión basada en predicciones sobre observaciones no utilizadas para ajustar el modelo correspondiente y al menos dos medidas adicionales vistas en clase: sensibilidad, especificidad, precisión, F1 o exactitud balanceada. Justifica cuáles son relevantes para este problema y explica qué errores comete cada método. Incluye una comparación con una regla sencilla de referencia, como predecir siempre la clase mayoritaria del entrenamiento.

5. **Emite una recomendación.** Elige el clasificador que utilizarías y defiende tu decisión. No basta con identificar el menor error de una tabla: considera la magnitud de las diferencias, su estabilidad, los tipos de equivocaciones y las limitaciones de la muestra.

Tu conclusión debe responder:

- ¿Qué clasificador usarías y por qué?
- Si recibieras 100 observaciones nuevas de una población comparable, £cuántas esperarías clasificar correctamente, aproximadamente?
- ¿Qué tan segura es esa estimación? Sustenta tu respuesta con la variabilidad observada en la validación o con una medida de incertidumbre apropiada; explica su alcance.
- ¿Qué podría cambiar si los datos provinieran de otro hospital o de una población diferente?

Distingue el desempeño promedio estimado de la certeza de acertar en un caso individual. La desviación entre *folds* o remuestreos no constituye, por sí sola, un intervalo de confianza.

Entregables

Reporte de 4–6 páginas, sin contar referencias. Debe permitir entender el problema, tus decisiones, el diseño de evaluación, los resultados y la recomendación final. Incluye una tabla comparativa y únicamente las figuras que ayuden a sostener tu argumento. Cita el artículo y el conjunto de datos.

Código reproducible, en un *notebook* `.ipynb` o un archivo `.py`, acompañado de instrucciones breves de ejecución y las dependencias necesarias. Debe cargar los datos, realizar la preparación, entrenar y evaluar los clasificadores y generar las tablas o figuras del reporte. Registra las semillas aleatorias y la versión o fecha de descarga de los datos. Si entregas un *notebook*, debe poder ejecutarse completo en orden.